PREDIKSI KECEPATAN ANGIN MAKSIMUM HARIAN MENGGUNAKAN RANDOM FOREST DAN XGBOOST

Penulis Pertama [1] Carlo Rafael Kurniaji

[1] Sistem Informasi, Universitas Tarumanagara
Jl. Merdeka 10, Jakarta 12020 Indonesia
email : carlo.825240020@stu.untar.ac.id

ABSTRACT

Wind speed is an important meteorological variable that influences weather-related planning and decision making. This study compares Random Forest and XGBoost regression models for predicting daily maximum wind speed at a height of 10 m. The data were obtained from Open-Meteo and cover the period from 1 January 2015 to 31 December 2023 (3,287 daily observations) at coordinates 3.97°S, 119.83°E. Nine meteorological variables were used as predictors, and the data were split chronologically into 70:30 and 80:20 training-testing ratios to preserve temporal order. Model performance was evaluated using MAE, RMSE, and R^2. The best result was obtained by XGBoost with the 80:20 split (MAE = 2.2270 km/h, RMSE = 2.8043 km/h, R^2 = 0.5968), followed by Random Forest on the same split (MAE = 2.2718 km/h, RMSE = 2.8704 km/h, R^2 = 0.5775). Relative humidity was the most influential predictor in both models. The results show that both models explain a moderate share of the variability in wind speed, and that the performance differences between the two models are small.

Key words

Wind speed prediction, Random Forest, XGBoost, regression, weather data

1. Pendahuluan

Pada 2025, bauran energi baru dan terbarukan ditargetkan oleh Pemerintah Indonesia mencapai 23%, sedangkan potensi tenaga angin nasional diestimasikan sebesar 60,6 GW meskipun tingkat pemanfaatannya masih tergolong sangat rendah[1]. Peresmian Pembangkit Listrik Tenaga Bayu (PLTB) Sidrap pada 2 Juli 2018 menjadi salah satu upaya merealisasikan target tersebut. PLTB Sidrap merupakan pembangkit listrik tenaga angin berskala komersial pertama sekaligus terbesar di Indonesia, dengan kapasitas 75 MW yang dihasilkan dari 30 turbin, masing-masing berkapasitas 2,5 MW. Berlokasi di Kecamatan Watang Pulu, Kabupaten Sidenreng Rappang, fasilitas yang diresmikan pada 2 Juli 2018 tersebut adalah pembangkit tenaga angin komersial pertama di Indonesia dan dilengkapi 30 turbin berkapasitas masing-masing 2,5 MW[1][2].

Fluktuasi kecepatan angin menyebabkan keluaran daya listrik turbin angin sangat bergantung pada parameter tersebut. Oleh sebab itu, akurasi prediksi kecepatan angin berperan krusial dalam menjamin efisiensi pembangkitan sekaligus keandalan integrasi ke jaringan listrik [3]. Di PLTB Sidrap, ketidakstabilan daya listrik yang dihasilkan dipicu oleh kecepatan angin yang juga tidak stabil [4]. Prediksi kecepatan angin menjadi rumit karena banyak faktor atmosfer saling berinteraksi suhu, tekanan, kelembapan, dan tutupan awan dengan hubungan antarvariabel yang umumnya tidak linear.

Sejumlah studi *machine learning* telah mengadopsi pembelajaran mesin untuk memprediksi kecepatan angin. Zabihi dkk.[3] membandingkan SVM, Random Forest, jaringan saraf tiruan, dan XGBoost dengan memanfaatkan data Open-Meteo; hasilnya menunjukkan SVM sebagai model paling akurat, sedangkan Random Forest dan XGBoost menghasilkan RMSE yang relatif setara. Mugware dkk. [5] menguji CNN, DAN2, Random Forest, dan XGBoost pada karakteristik cuaca Afrika Selatan, sementara Elmousalami dkk. [6] mengevaluasi algoritma pembelajaran mesin dan pembelajaran mendalam untuk prediksi kecepatan angin dan daya. Secara khusus, Sathyaraj dan Sankardoss [7] menganalisis model regresi Random Forest dalam peramalan kecepatan angin; Hussain dkk. [8] menerapkan XGBoost untuk memprediksi kecepatan angin bulanan; dan Kim dan Ko [9] membandingkan XGBoost, Random Forest, serta SVM untuk peramalan daya angin satu hari ke depan. Di lain pihak, pendekatan hibrida yang berbasis dekomposisi sinyal dan jaringan saraf dalam, sebagaimana dikembangkan oleh Zhu dkk. [10], Geng dkk.[11], dan Du dkk.[12], t erus diteliti guna meningkatkan akurasi. Tinjauan terkini juga menegaskan luasnya penggunaan pembelajaran mesin di sektor energi terbarukan [13][14]. Pada lokasi yang tidak memiliki stasiun pengukuran, pembelajaran mesin bahkan dimanfaatkan untuk mengestimasi deret waktu kecepatan angin per jam [15]. XGBoost juga dipakai dalam model peramalan daya angin ultra-jangka pendek[16], dan berbagai metode *machine learning* telah dibandingkan untuk memperkirakan daya keluaran dan kecepatan angin pada studi kasus di Texas[17].

Meskipun demikian, penelitian prediksi yang secara spesifik menyasar PLTB Sidrap dan berhasil kami temukan masih terbatas. Asy'ari dkk.[4], misalnya,

membangun model *autoregressive* untuk memprediksi daya listrik PLTB Sidrap menggunakan data selama 14 hari dengan interval 30 menit. Padahal, data cuaca harian multitahun dari sumber terbuka tersedia untuk lokasi tersebut.

Penelitian ini bertujuan untuk: (1) memprediksi kecepatan angin maksimum harian pada ketinggian 10 m di kawasan PLTB Sidrap berdasarkan sembilan variabel cuaca; (2) membandingkan kinerja Random Forest dan XGBoost; (3) menguji pengaruh rasio pembagian data 70:30 dan 80:20; dan (4) mengidentifikasi variabel yang paling berpengaruh terhadap prediksi. Kontribusi makalah ini adalah perbandingan terkontrol dua model pada data harian selama sembilan tahun di lokasi PLTB Sidrap dengan pembagian data berurutan waktu, yang dapat menjadi *baseline* bagi penelitian peramalan angin selanjutnya.

2. Landasan Teori

2.1 PLTB Sidrap

PLTB Sidrap menempati posisi sebagai pembangkit listrik tenaga angin komersial pertama sekaligus terbesar di Indonesia. Peresmiannya berlangsung pada 2 Juli 2018 dan berlokasi di Kecamatan Watang Pulu, Kabupaten Sidenreng Rappang, Sulawesi Selatan [2]. Daya terpasangnya mencapai 75 MW yang dihasilkan oleh 30 turbin, masing-masing berkapasitas 2,5 MW, dengan menara setinggi 80 m dan bilah sepanjang 57 m [18]. Rangkuman spesifikasi utamanya disajikan pada Tabel 1. Bersama PLTB Tolo (72 MW), PLTB Sidrap tergolong sebagai dua pembangkit tenaga angin berskala besar di Indonesia, sedangkan potensi angin nasional diproyeksikan mencapai 60,6 GW. Oleh karena itu, kecakapan dalam memprediksi kondisi angin pada lokasi semacam ini menjadi relevan bagi pengembangan pembangkit sejenis.

Tabel 1 Spesifikasi PLTB Sidrap

Parameter	Keterangan
Lokasi	Kec. Watang Pulu, Kab. Sidenreng Rappang, Sulawesi Selatan
Kapasitas terpasang	75 MW
Jumlah turbin	30 unit
Kapasitas per turbin	2,5 MW
Tinggi menara	80 m
Panjang bilah	57 m
Pengembang/operator	PT UPC Sidrap Bayu Energi
Peresmian	2 Juli 2018

2.2 Kecepatan Angin dan Variabel Meteologi

Perbedaan tekanan udara antarwilayah, yang dipengaruhi oleh pemanasan permukaan bumi, menjadi penyebab munculnya angin. Pada kajian ini, variabel target yang dipakai ialah kecepatan angin maksimum harian pada ketinggian 10 m. Sementara itu, variabel prediktor terdiri atas suhu udara (rata-rata, maksimum, minimum), tekanan permukaan, kelembapan relatif, tutupan awan, radiasi gelombang pendek, arah angin dominan, serta kode cuaca WMO. Kode cuaca WMO merupakan kode baku yang merepresentasikan kondisi cuaca harian, misalnya cerah, berawan, atau hujan dengan berbagai intensitas.

2.3 Random Forest

Dalam Random Forest, sejumlah B pohon keputusan dikonstruksi; setiap pohon dilatih menggunakan sampel bootstrap yang diambil dari data latih, dan pada setiap pemisahan simpul hanya sebagian fitur yang dipertimbangkan secara acak. Untuk regresi, prediksi akhir adalah rata-rata prediksi seluruh pohon:

$$\hat{y}(x) = \frac{1}{B}\sum_{b=1}^{B} T_b(x) \quad \ldots\ldots (1)$$

dengan:

- $\hat{y}(x)$ = nilai prediksi akhir Random Forest untuk data masukan x
- x = vektor fitur (variabel prediktor) satu data
- B = jumlah pohon keputusan dalam hutan (n_estimators)
- b = indeks pohon, dari 1 sampai B
- T_b(x) = prediksi pohon ke-b untuk data masukan x

Karena data dan fitur diacak, antarpohon memiliki korelasi yang rendah, akibatnya, rata-rata prediksi menghasilkan varians lebih kecil daripada prediksi satu pohon tunggal. Dengan demikian, risiko overfitting dapat ditekan. Random Forest turut menghasilkan tingkat kepentingan fitur, yang diperoleh melalui rata-rata penurunan ketidakmurnian (impurity) yang disumbangkan oleh tiap fitur pada keseluruhan pohon. Makin besar penurunan tersebut, makin krusial peran fitur bersangkutan dalam model.

2.4 XGBoost

XGBoost (Extreme Gradient Boosting) dikenal sebagai implementasi efisien bagi metode gradient boosting. Berbeda dari Random Forest yang mengonstruksi pohon secara paralel dan independen, XGBoost menyusun pohon secara berurutan: tiap pohon baru dilatih guna memperbaiki kesalahan (galat) yang masih tersisa dari gabungan pohon sebelumnya. Prediksi model diekspresikan sebagai hasil penjumlahan dari seluruh pohon:

$$\hat{y}_i = \sum_{k=1}^{K} f_k(x_i) \quad \ldots\ldots(2)$$

dengan:

- ŷ_i = nilai prediksi untuk data ke-i
- K = jumlah pohon (n_estimators)
- k = indeks pohon, dari 1 sampai K
- f_k = pohon regresi ke-k
- x_i = vektor fitur data ke-i

Model dilatih dengan meminimalkan fungsi tujuan yang terdiri dari fungsi kerugian dan penalti kompleksitas:

$$L = \sum_{i=1}^{n} l(y_i, \hat{y}_i) + \sum_{k=1}^{K} \Omega(f_k), \quad dengan\ \Omega(f) = \gamma T + \frac{1}{2}\lambda||w||^2 \quad \ldots\ldots(3)$$

dengan:

- L = fungsi tujuan yang diminimalkan
- n = jumlah data latih
- l(y_i, ŷ_i) = fungsi kerugian, yaitu ukuran selisih antara nilai aktual y_i dan prediksi ŷ_i (pada regresi umumnya kuadrat selisih)
- Ω(f_k) = penalti kompleksitas untuk pohon ke-k
- T = jumlah daun pada pohon
- w = vektor bobot (nilai keluaran) pada daun-daun pohon
- ‖w‖² = jumlah kuadrat bobot daun
- γ = parameter penalti untuk jumlah daun; semakin besar γ, semakin dihindari pohon yang banyak daunnya
- λ = parameter regularisasi L2 yang menekan besarnya bobot daun

Penalti Ω membatasi kompleksitas pohon sehingga mengurangi *overfitting*. Parameter penting dalam XGBoost meliputi jumlah pohon (n_estimators), laju pembelajaran (learning_rate) yang mengatur besar kontribusi tiap pohon baru, dan kedalaman maksimum pohon (max_depth) yang membatasi kerumitan tiap pohon.

2.5 Metrik Evaluasi

Kinerja model regresi dalam penelitian ini diukur dengan tiga metrik, yaitu *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), dan koefisien determinasi (R^2).

MAE menyatakan rata-rata besar galat mutlak antara nilai aktual dan prediksi:

$$MAE = \frac{1}{n}\sum_{i=1}^{n} |y_i - \hat{y}_i| \quad \ldots\ldots(4)$$

RMSE adalah akar dari rata-rata kuadrat galat:

$$RMSE = \sqrt{\frac{1}{2}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \quad \ldots\ldots(5)$$

R^2 menyatakan proporsi variasi target yang dapat dijelaskan model:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y}_i)^2} \quad \ldots\ldots(6)$$

dengan keterangan untuk persamaan (4) sampai (6):

- n = jumlah data uji
- i = indeks data, dari 1 sampai n
- y_i = nilai aktual kecepatan angin pada data ke-i (km/jam)
- ŷ_i = nilai prediksi kecepatan angin pada data ke-i (km/jam)
- ȳ = rata-rata nilai aktual pada seluruh data uji, yaitu ȳ = (1/n) Σ y_i

MAE dan RMSE diperlakukan sebagai metrik yang satuannya sejalan dengan variabel target, yaitu km/jam, semakin rendah nilai keduanya, semakin baik kinerja yang ditunjukkan. Dalam RMSE, galat dikuadratkan terlebih dahulu sebelum proses perata-rataan dilakukan, sehingga bobot yang lebih besar diberikan kepada galat berukuran besar dan metrik ini menjadi lebih peka terhadap nilai ekstrem. Adapun MAE memperlakukan seluruh galat secara proporsional. Oleh sebab itu, kedua metrik tersebut bersifat saling melengkapi. Pada R^2, nilai 1 menandakan prediksi sempurna, nilai 0 menunjukkan bahwa model tidak lebih baik daripada prediksi rata-rata ȳ, sedangkan nilai negatif mengindikasikan bahwa model lebih buruk daripada prediksi rata-rata tersebut.

2.6 Alur Penelitian

Penelitian dilakukan dalam sembilan tahapan berikut:

1. Pengumpulan data cuaca harian dari Open-Meteo untuk lokasi PLTB Sidrap.
2. Pemeriksaan kualitas data, yaitu pengecekan nilai hilang, duplikasi, dan kelengkapan deret waktu.
3. Pra-pemrosesan data.
4. Eksplorasi data melalui statistik deskriptif, visualisasi deret waktu, dan analisis korelasi.
5. Pemilihan variabel prediktor dan variabel target.
6. Pembagian data latih dan data uji berdasarkan urutan waktu dengan rasio 70:30 dan 80:20.
7. Pelatihan model Random Forest dan XGBoost pada masing-masing skenario.
8. Prediksi pada data uji dan evaluasi dengan MAE, RMSE, dan R^2.
9. Analisis tingkat kepentingan fitur dan penarikan kesimpulan.

Seluruh proses dijalankan dengan bahasa pemrograman Python pada Jupyter Notebook, menggunakan pustaka pandas dan NumPy untuk

pengolahan data, Matplotlib untuk visualisasi, scikit-learn untuk Random Forest dan pembagian data, serta XGBoost untuk model *gradient boosting*.

2.7 Data dan Variabel Penelitian

Data yang digunakan adalah data cuaca harian dari Open-Meteo [19] pada koordinat 3,97°LS dan 119,83°BT yang merepresentasikan kawasan PLTB Sidrap, Sulawesi Selatan. Rentang data meliputi 1 Januari 2015 hingga 31 Desember 2023. Open-Meteo telah dimanfaatkan sebagai sumber data terbuka dalam penelitian prediksi kecepatan angin berbasis *machine learning* [3].

Dataset ini mencakup 3.287 baris (satu baris untuk setiap hari) dan 12 kolom. Hasil pemeriksaan mutu data mengungkap tiga temuan. Pertama, tidak ditemukan nilai hilang pada keseluruhan kolom. Kedua, tidak terdapat tanggal yang terduplikasi. Ketiga, banyaknya baris setara dengan jumlah hari dalam rentang waktu tersebut, sehingga deret waktu dinyatakan lengkap tanpa hari yang terlewat.

Perlu dicatat bahwa data Open-Meteo tidak berasal dari pengukuran langsung pada turbin, melainkan dari model cuaca beresolusi grid. Evaluasi data reanalisis ERA5 terhadap pengukuran di Inggris memperlihatkan adanya bias pada rata-rata kecepatan angin serta kecenderungan untuk meremehkan variabilitas per jam, dengan galat terbesar muncul pada lokasi pesisir dan pegunungan [20]. Keterbatasan ERA5 pada wilayah pesisir dan lepas pantai juga diidentifikasi oleh studi lain [21]. Selain itu, kecepatan angin yang digunakan berada pada ketinggian 10 m, sementara menara turbin PLTB Sidrap memiliki ketinggian 80 m (Tabel 1). Kedua kondisi tersebut menjadi batasan dalam menafsirkan hasil penelitian ini.

ariabel target yang ditetapkan ialah kecepatan angin maksimum harian pada ketinggian 10 m (wind_speed_10m_max). Sebanyak sembilan variabel lain berperan sebagai prediktor. Rincian variabel beserta satuannya disajikan pada Tabel 2.

Tabel 2 Variabel Penelitian

No	Variabel	Keterangan	Satuan	Peran
1	wind_speed_10m_max	Kecepatan angin maksimum harian pada 10 m	km/jam	Target
2	weather_code	Kode kondisi cuaca harian (WMO)	kode	Prediktor
3	temperature_2m_mean	Suhu udara rata-rata pada 2 m	°C	Prediktor
4	temperature_2m_max	Suhu udara maksimum pada 2 m	°C	Prediktor
5	temperature_2m_min	Suhu udara minimum pada 2 m	°C	Prediktor
6	wind_direction_10m_dominant	Arah angin dominan pada 10 m	°	Prediktor
7	surface_pressure_mean	Tekanan permukaan rata-rata	hPa	Prediktor
8	relative_humidity_2m_mean	Kelembapan relatif rata-rata pada 2 m	%	Prediktor
9	cloud_cover_mean	Tutupan awan rata-rata	%	Prediktor
10	shortwave_radiation_sum	Jumlah radiasi gelombang pendek harian	MJ/m²	Prediktor

Terdapat dua kolom yang tidak diikutsertakan sebagai prediktor. Kolom tanggal (*time*) hanya dimanfaatkan untuk mengurutkan data. Adapun kolom kecepatan hembusan angin maksimum (*wind_gusts_10m_max*) tidak digunakan sebab korelasinya dengan target sangat tinggi, yaitu 0,9579, sehingga informasinya nyaris serupa. Apabila kolom tersebut digunakan, permasalahan prediksi akan menjadi tidak realistis karena nilai hembusan angin belum tersedia sebelum kecepatan angin itu sendiri diketahui.

2.8 Pra-pemrosesan dan Analisis Korelasi

Tahap pra-pemrosesan dijalankan secara minimal karena kualitas data telah tergolong baik. Kolom tanggal dikonversi ke tipe datetime supaya data dapat diurutkan dan dipisahkan berdasarkan waktu. Oleh karena tidak ditemukan nilai hilang maupun duplikat, imputasi atau penghapusan data tidak dilakukan. Normalisasi maupun standardisasi fitur juga tidak diterapkan karena Random Forest dan XGBoost merupakan model berbasis pohon keputusan yang menentukan pemisahan berdasarkan urutan nilai, bukan berdasarkan skala fitur. Kode cuaca WMO diperlakukan sebagai variabel numerik sebagaimana adanya.

Sebelum pemodelan, hubungan linear antara tiap variabel dan kecepatan angin maksimum diperiksa dengan koefisien korelasi Pearson:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x_i})(y_i - \bar{y_i})}{\sqrt{(\sum_{i=1}^{n}(x_i - \bar{x_i})^2 \cdot \sum_{i=1}^{n}(y_i - \bar{y_i})^2}} \quad \ldots\ldots (7)$$

dengan:

- r = koefisien korelasi Pearson, bernilai antara −1 dan 1
- n = jumlah data (3.287)
- x_i = nilai variabel prediktor pada hari ke-i
- y_i = nilai kecepatan angin maksimum pada hari ke-i (km/jam)

- $\bar{x}$ = rata-rata variabel prediktor
- $\bar{y}$ = rata-rata kecepatan angin maksimum

Nilai r mendekati 1 menunjukkan hubungan linear positif yang kuat, mendekati −1 menunjukkan hubungan linear negatif yang kuat, dan mendekati 0 menunjukkan tidak ada hubungan linear. Korelasi hanya mengukur hubungan linear sehingga tidak menangkap hubungan non-linear yang mungkin dipelajari oleh model berbasis pohon.

2.9 Pembagian Data Latih dan Data Uji

Pembagian data dilakukan mengikuti kronologi waktu, yaitu tanpa dilakukannya pengacakan (shuffle=False). Alasan pemilihan pendekatan tersebut adalah bahwa pengacakan pada data deret waktu berpotensi memasukkan informasi dari periode yang berada setelah data uji ke dalam data latih, atau yang dikenal sebagai kebocoran temporal, sehingga evaluasi yang dihasilkan menjadi terlalu optimistis [22]. Upaya mencegah kebocoran informasi turut menjadi perhatian dalam studi peramalan energi angin [23]. Rasio 70:30 juga digunakan pada penelitian prediksi daya PLTB Sidrap [4]. Jumlah data latih ditentukan sebagai berikut:

$$n_{latih} = \lfloor \rho \times \mathrm{N} \rfloor, \; n_{uji} = N - n_{latih} \quad \ldots\ldots (8)$$

dengan:

- n_latih = jumlah data latih
- n_uji = jumlah data uji
- N = jumlah seluruh data (3.287)
- ρ = proporsi data latih (0,7 atau 0,8)
- $\lfloor \cdot \rfloor$ = pembulatan ke bawah

Dua skenario digunakan, yaitu 70:30 dan 80:20, yang rinciannya disajikan pada Tabel 3. Pada skenario 70:30, n_latih = $\lfloor 0{,}7 \times 3.287 \rfloor$ = 2.300. Pada skenario 80:20, n_latih = $\lfloor 0{,}8 \times 3.287 \rfloor$ = 2.629.

Tabel 3 Skenario pembagian data

Skenario	Data latih	Periode latih	Data uji	Periode uji
70:30	2.300	1 Jan 2015 - 18 Apr 2021	987	19 Apr 2021 - 31 Des 2023
80:20	2.629	1 Jan 2015 - 13 Mar 2022	658	14 Mar 2022 - 31 Des 2023

Meskipun kedua skenario berbagi titik awal periode pelatihan yang identik, periode pengujiannya tidak sama, data uji pada skenario 80:20 menempati segmen akhir dari data uji skenario 70:30. Fakta ini mesti diperhatikan ketika hasil kedua skenario dibandingkan.

2.10 Konfigurasi Model

Penelitian ini menerapkan dua model regresi. Model pertama, Random Forest Regressor yang berasal dari pustaka scikit-learn, dibangun dengan 100 pohon keputusan (n_estimators=100). Adapun model kedua, XGBoost Regressor, dikonfigurasi menggunakan 100 pohon, laju pembelajaran 0,1, serta kedalaman maksimum pohon 6. Agar hasil dapat direproduksi, random_state=42 diterapkan pada kedua model. Nilai bawaan pustaka digunakan untuk parameter lain, dan penyetelan hiperparameter tidak dilakukan [konfirmasi]. Rincian konfigurasi secara utuh tersaji pada Tabel 4. Karena setiap model dilatih secara terpisah pada masing-masing skenario, terbentuk empat eksperimen: Random Forest 70:30, Random Forest 80:20, XGBoost 70:30, dan XGBoost 80:20.

Tabel 4 Konfigurasi Model

Parameter	Random Forest	XGBoost
n_estimators	100	100
learning_rate	-	0,1
max_depth	bawaan	6
random_state	42	42
n_jobs	-1	-1

Pemilihan 100 pohon merupakan nilai umum yang digunakan sebagai titik awal.

2.11 Evaluasi Model

Evaluasi kinerja model pada data uji dilakukan melalui MAE, RMSE, dan R^2, sebagaimana persamaan (4) hingga (6) di subbab 2.5. Ketiga metrik tersebut diterapkan secara bersamaan lantaran sifatnya yang saling melengkapi. MAE dan RMSE mengungkapkan besarnya galat dalam satuan km/jam, sementara R^2 menunjukkan proporsi variasi yang mampu dijelaskan oleh model.

Evaluasi kuantitatif tersebut dilengkapi oleh evaluasi visual, yaitu grafik yang membandingkan nilai aktual dengan nilai prediksi pada data uji bagi setiap eksperimen. Sebagai langkah terakhir, tingkat kepentingan fitur diperoleh dari model skenario 80:20 guna mengidentifikasi variabel yang memberikan kontribusi terbesar terhadap prediksi.

3. Hasil Percobaan

3.1 Eksplorasi Data

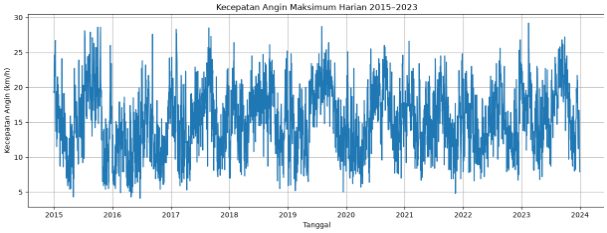
Hasil statistik deskriptif untuk data yang dianalisis disajikan dalam Tabel 5. Untuk kecepatan angin maksimum harian, diperoleh rerata 15,31 km/jam dan simpangan baku 4,71 km/jam, dengan rentang nilai dari 4,1 km/jam hingga 29,2 km/jam. Mediannya, yakni 15,3 km/jam, berada hampir setara dengan rerata sehingga distribusi data dapat dikatakan cenderung simetris. Sementara itu, suhu rata-rata harian tercatat sangat stabil, yaitu 26,56 °C dengan simpangan baku 0,98 °C, suatu karakteristik yang memang umum ditemui di wilayah tropis. Adapun kelembapan relatif rata-rata mencapai 82,51%, sedangkan tutupan awan rata-rata sebesar 78,48%.

Tabel 5 Statistik deskriptif data (n=3.287)

Variabel	Rata-rata	Std	Min	25%	50%	75%	Maks
Kecepatan angin maks (km/jam)	15,31	4,71	4,1	11,7	15,3	18,8	29,2

Variabel	Rata-rata	Std	Min	25%	50%	75%	Maks
Hembusan angin maks (km/jam)	37,17	9,74	13,7	29,5	37,1	44,3	73,4
Kode cuaca	48,38	20,11	0	51	53	61	65
Suhu rata-rata (°C)	26,56	0,98	23,1	25,9	26,5	27,1	29,9
Suhu maks (°C)	30,46	1,79	24,2	29,4	30,4	31,5	36,7
Suhu min (°C)	24,00	0,70	21,1	23,6	24,0	24,4	27,4
Arah angin dominan (°)	176,73	78,28	1	117	126	271	357
Tekanan permukaan (hPa)	1009,40	1,41	1004,2	1008,5	1009,5	1010,4	1013,9
Kelembapan relatif (%)	82,51	7,78	50	79	84	88	99
Tutupan awan (%)	78,48	21,85	5	66,5	86	96	100
Radiasi gelombang pendek (MJ/m²)	18,77	4,22	2,36	16,58	19,49	21,70	28,42

Pola temporal kecepatan angin maksimum sepanjang 2015-2023 diilustrasikan pada Gambar 1. Berdasarkan gambar tersebut, fluktuasi tajam terjadi pada kecepatan angin maksimum harian dari satu hari ke hari berikutnya, dengan perbedaan antarhari yang dapat mencapai 5-10 km/jam. Di atas fluktuasi tersebut, teridentifikasi siklus naik-turun yang berulang secara tahunan. Pada sejumlah tahun, misalnya 2015, 2017, 2019, dan 2023, kecepatan angin cenderung meningkat pada pertengahan hingga akhir tahun (sekitar Juni-Oktober) dan mencapai puncak mendekati 28 km/jam, sementara nilai terendahnya biasanya berada dalam kisaran 5-10 km/jam. Namun, waktu dan besaran puncak tidak seragam antartahun: 2016 cenderung rendah hampir sepanjang tahun, nilai tertinggi sepanjang periode (29,2 km/jam) muncul pada awal 2023, dan nilai terendah (4,1 km/jam) tercatat pada pertengahan 2016. Tidak ada indikasi tren jangka panjang yang jelas, baik naik maupun turun, selama sembilan tahun tersebut. Keberadaan pola musiman ini mengisyaratkan bahwa data menyimpan struktur waktu yang belum dimanfaatkan oleh model, sebab model hanya mengandalkan variabel cuaca pada hari yang sama.



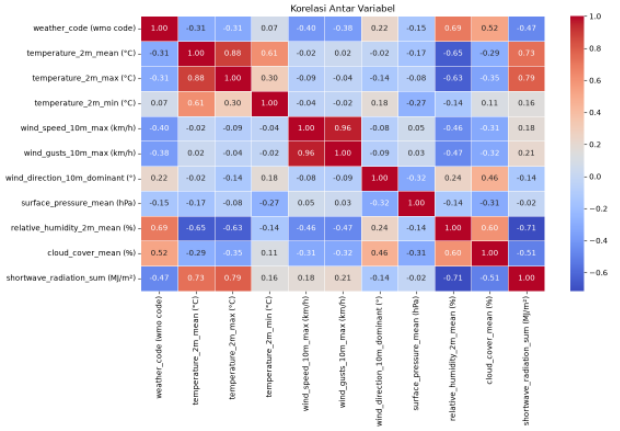
Gambar 1 Kecepatan angin maksimum harian 2015-2023

Keterkaitan variabel prediktor dengan target diuji melalui korelasi Pearson mengikuti persamaan (7), dan hasilnya ditampilkan pada Tabel 6. Korelasi paling kuat ditemukan pada kelembapan relatif (−0,4583), kode cuaca (−0,4016), dan tutupan awan (−0,3138), yang seluruhnya bernilai negatif. Dengan demikian, hari yang lebih lembap, lebih berawan, serta memiliki kode cuaca lebih tinggi (hujan) cenderung dicirikan oleh kecepatan angin maksimum yang lebih rendah. Radiasi gelombang pendek memperlihatkan korelasi positif lemah (0,1790), sejalan dengan kecenderungan langit lebih cerah pada hari berangin. Suhu, tekanan, dan arah angin hanya memiliki korelasi yang sangat lemah ($|r| < 0{,}1$). Meskipun demikian, hubungan non-linear antara variabel-variabel tersebut dan target tetap mungkin terjadi, karena korelasi Pearson hanya mampu menangkap keterkaitan linear.

Gambar 2 menyajikan peta panas korelasi antarseluruh variabel. Baris yang mewakili kecepatan angin maksimum mengonfirmasi temuan pada Tabel 6: kelembapan relatif (−0,46), kode cuaca (−0,40), dan tutupan awan (−0,31) berkorelasi negatif, sedangkan radiasi gelombang pendek berkorelasi positif lemah (0,18). Kecepatan angin dan hembusan angin menunjukkan korelasi yang sangat kuat (0,96). Peta panas tersebut juga mengungkapkan bahwa beberapa prediktor saling berkorelasi, yakni suhu rata-rata dengan suhu maksimum (0,88), suhu maksimum dengan radiasi (0,79), kelembapan dengan radiasi (−0,71), kelembapan dengan kode cuaca (0,69), serta kelembapan dengan tutupan awan (0,60). Kelembapan relatif berhubungan erat dengan kondisi langit secara keseluruhan (awan, hujan, dan radiasi), sehingga perannya dalam model berpotensi sebagian merepresentasikan informasi dari variabel-variabel tersebut. Keterkaitan antarprediktor tersebut umumnya tidak menurunkan akurasi model berbasis pohon, tetapi dapat menyulitkan penafsiran tingkat kepentingan setiap fitur (lihat subbab 3.3).

Tabel 6 Korelasi variabel terhadap kecepatan angin maksimum

Variabel	Korelasi (r)
Radiasi gelombang pendek	0,1790
Tekanan permukaan	0,0495
Suhu rata-rata	−0,0164
Suhu min	−0,0390
Arah angin dominan	−0,0813
Suhu maks	−0,0851
Tutupan awan	−0,3138
Kode cuaca	−0,4016
Kelembapan relatif	−0,4583



Gambar 2 Korelasi antar variabel

3.2 Kinerja Model

Hasil seluruh eksperimen pada data uji ditunjukkan pada Tabel 7.

Tabel 7 Perbandingan kinerja model pada data uji

Model	Pembagian	MAE (km/jam)	RMSE (km/jam)	R^2
Random Forest	70:30	2,3155	2,9454	0,5446
Random Forest	80:20	2,2718	2,8704	0,5775
XGBoost	70:30	2,2815	2,8934	0,5605
XGBoost	80:20	2,2270	2,8043	0,5968

Kinerja paling unggul pada kedua skenario ditunjukkan oleh XGBoost. Dalam skenario 80:20, MAE berhasil ditekan oleh XGBoost sekitar 2,0% (dari 2,2718 menjadi 2,2270 km/jam) dan RMSE sekitar 2,3% (dari 2,8704 menjadi 2,8043 km/jam) jika dibandingkan dengan Random Forest; selain itu, R^2 meningkat dari 0,5775 menjadi 0,5968. Pada skenario 70:30, XGBoost turut lebih unggul dengan MAE 2,2815 berbanding 2,3155 km/jam dan R^2 0,5605 berbanding 0,5446.

Galat paling rendah (MAE 2,2270 km/jam) ekuivalen dengan sekitar 14,6% dari rata-rata kecepatan angin seluruh data (15,31 km/jam), sedangkan galat paling tinggi (2,3155 km/jam) ekuivalen dengan sekitar 15,1%. Nilai R^2 sebesar 0,54-0,60 menandakan bahwa model mampu menerangkan sekitar setengah hingga enam persepuluh variasi kecepatan angin maksimum harian. Kinerja tersebut tergolong moderat: pola umum telah tertangkap oleh model, tetapi sisa variasi belum dapat diterangkan oleh variabel cuaca harian yang tersedia.

Pada skenario 80:20, performa kedua model tercatat lebih tinggi dibandingkan skenario 70:30. Kondisi ini kemungkinan tidak terlepas dari jumlah data latih yang lebih besar, yakni 2.629 hari berbanding 2.300 hari. Akan tetapi, periode pengujian pada masing-masing skenario tidak sama (658 hari berbanding 987 hari); oleh sebab itu, disparitas metrik antara kedua skenario tidak dapat sepenuhnya diatribusikan kepada volume data latih. Perbedaan yang muncul, baik antarmodel maupun antarskenario, terbilang kecil, sementara eksperimen hanya menggunakan satu nilai random seed. Atas dasar itu, superioritas XGBoost lebih layak diposisikan sebagai petunjuk awal, bukan sebagai simpulan yang final.

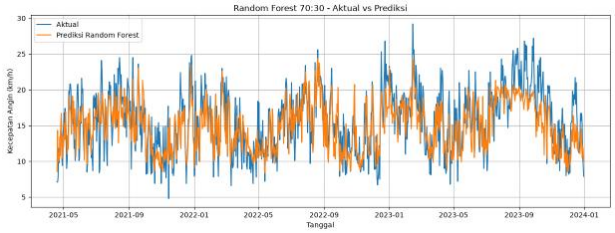
Temuan tersebut sejalan dengan kajian terdahulu yang mengindikasikan bahwa performa Random Forest dan XGBoost cenderung berdekatan dalam prediksi kecepatan angin. Zabihi dkk. [3] melaporkan RMSE kedua model yang setara (sekitar 1,08), sedangkan MAE XGBoost lebih kecil (0,888 berbanding 1,031), pola ini menyerupai Tabel 7, tempat XGBoost sedikit lebih unggul pada ketiga metrik. Meskipun demikian, peringkat model sangat ditentukan oleh karakteristik data dan lokasi; SVM menjadi yang paling akurat pada penelitian [3], CNN unggul dibanding model individual lain pada penelitian [5], dan Random Forest lebih baik daripada model tunggal pada beragam skala waktu pada penelitian [6]. Lantaran data, target, serta skala waktu yang digunakan berbeda, angka metrik dari berbagai penelitian tidak dapat diperbandingkan secara langsung.

Tabel 8 menyajikan contoh perbandingan antara nilai aktual dan prediksi XGBoost pada skenario 80:20 untuk sepuluh hari pertama data uji. Pada sejumlah hari, prediksi tampak sangat mendekati nilai aktual (contohnya 14 dan 20 Maret 2022 dengan selisih di bawah 0,2 km/jam), tetapi pada hari lain kesalahan cukup besar, seperti 18 Maret (selisih 4,27 km/jam) dan 19 Maret 2022 (3,81 km/jam).

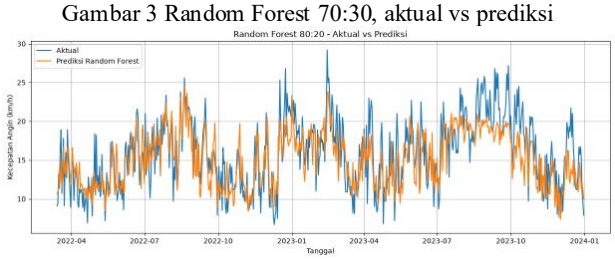
Tabel 8 Contoh nilai aktual dan prediksi XGBoost (80:20)

Tanggal	Aktual (km/jam)	Prediksi (km/jam)	Galat mutlak
14-03-2022	9,1	9,10	0,00
15-03-2022	9,4	11,98	2,58
16-03-2022	13,2	11,95	1,25
17-03-2022	11,4	13,29	1,89
18-03-2022	16,6	12,33	4,27
19-03-2022	18,9	15,09	3,81
20-03-2022	10,7	10,90	0,20
21-03-2022	14,1	12,49	1,61
22-03-2022	17,8	16,72	1,08
23-03-2022	9,1	12,88	3,78

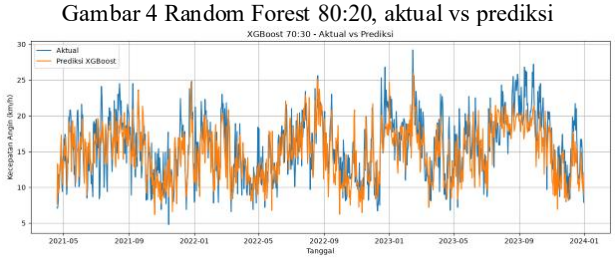
Perbandingan antara nilai aktual dan hasil prediksi pada keseluruhan data uji untuk keempat eksperimen diperlihatkan melalui Gambar 3 sampai Gambar 6. Pola yang tampak pada keempat grafik tersebut relatif serupa. Garis prediksi (oranye) mampu mengikuti kecenderungan naik-turun kecepatan angin dengan cukup baik, khususnya peralihan antara periode angin rendah (sekitar Oktober-November) dan periode angin tinggi (misalnya pertengahan 2022 dan 2023). Akan tetapi, hasil prediksi memperlihatkan kecenderungan lebih datar daripada data aktual, sehingga nilai-nilai ekstrem sering kali tidak tercapai. Puncak tertinggi sebesar 29,2 km/jam pada awal 2023 hanya diprediksi sekitar 24-26 km/jam oleh semua model. Pada Agustus-Oktober 2023, kecepatan aktual yang berfluktuasi antara sekitar 15 dan 27 km/jam diprediksi relatif stabil pada kisaran 18-21 km/jam; akibatnya, periode tersebut menjadi bagian dengan galat terbesar. Pada hari-hari dengan angin sangat rendah (sekitar 5-8 km/jam), prediksi cenderung sedikit lebih tinggi, terutama pada Random Forest. Perbedaan karakter antarmodel juga terlihat: Random Forest menghasilkan garis yang lebih halus dengan rentang sempit, sedangkan XGBoost lebih bergerigi dengan rentang lebih lebar (nilai terendah sekitar 6-7 km/jam dan puncak hingga sekitar 25-26 km/jam). Dengan demikian, XGBoost lebih responsif terhadap perubahan harian, sejalan dengan metriknya yang lebih baik pada Tabel 7. Secara visual, tidak tampak perbedaan besar antara skenario 70:30 dan 80:20, konsisten dengan selisih metrik yang kecil.



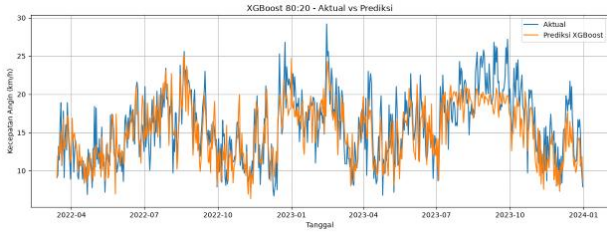
Gambar 3 Random Forest 70:30, aktual vs prediksi



Gambar 4 Random Forest 80:20, aktual vs prediksi



Gambar 5 XGBoost 70:30, aktual vs prediksi



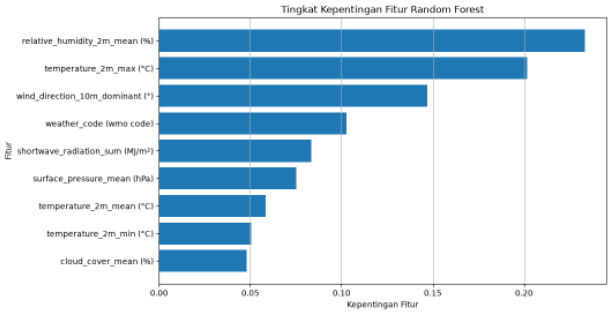
Gambar 6 XGBoost 80:20, aktual vs prediksi

3.3 Tingkat Kepentingan Fitur

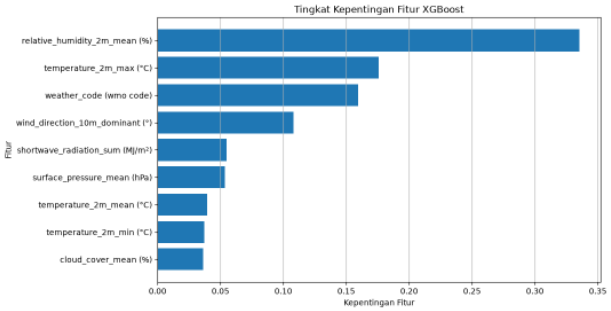
Tingkat kepentingan fitur dari model skenario 80:20 disajikan pada Tabel 9, Gambar 7, dan Gambar 8. Kelembapan relatif merupakan fitur paling berpengaruh pada kedua model (0,2335 pada Random Forest dan 0,3355 pada XGBoost), konsisten dengan korelasinya yang paling kuat terhadap target dalam analisis eksplorasi. Suhu maksimum menempati posisi kedua pada kedua model (0,2017 dan 0,1756). Pada Random Forest, urutan berikutnya adalah arah angin dominan (0,1469) dan kode cuaca (0,1028), sedangkan pada XGBoost kode cuaca (0,1596) berada di atas arah angin (0,1082). Tutupan awan memiliki kontribusi terkecil pada kedua model (0,0480 dan 0,0360).

Tabel 9 Tingkat Kepentingan Fitur (skenario 80:20)

Fitur	Random Forest	XGBoost
Kelembapan relatif	0,2335	0,3355
Suhu maksimum	0,2017	0,1756
Arah angin dominan	0,1469	0,1082
Kode cuaca	0,1028	0,1596
Radiasi gelombang pendek	0,0833	0,0551
Fitur	Random Forest	XGBoost
Tekanan permukaan	0,0751	0,0533
Suhu rata-rata	0,0584	0,0396
Suhu minimum	0,0505	0,0370
Tutupan awan	0,0480	0,0360



Gambar 7 Tingkat kepentingan fitur Random Forest



Gambar 8 Tingkat kepentingan fitur XGBoost

Kedua model sepakat pada dua fitur teratas, tetapi XGBoost memusatkan kepentingan lebih besar pada kelembapan. Beberapa catatan perlu diperhatikan dalam menafsirkan nilai-nilai ini. Pertama, kepentingan fitur berbasis impurity menunjukkan seberapa besar fitur dipakai model untuk mengurangi galat, bukan hubungan sebab-akibat. Kedua, suhu rata-rata, maksimum, dan minimum saling berkorelasi, sehingga kepentingannya terbagi di antara ketiganya dan masing-masing tampak lebih kecil daripada pengaruh gabungannya. Ketiga, tingginya peran kelembapan dapat mencerminkan pola cuaca musiman.

3.4 Implikasi bagi PLTB Sidrap

Hasil percobaan menunjukkan bahwa variabel cuaca harian dapat dipakai untuk menaksir kecepatan angin maksimum di kawasan PLTB Sidrap dengan galat rata-rata sekitar 2,2-2,3 km/jam. Dalam konteks operasional, nilai ini lebih tepat dipandang sebagai baseline ketimbang sistem peramalan siap pakai, karena tiga alasan. Pertama, data berasal dari grid model cuaca, bukan alat ukur pada turbin, dan evaluasi ERA5 menunjukkan galat yang lebih besar pada lokasi pesisir dan pegunungan [20]. Kedua, ketinggian pengukuran 10 m berbeda dari tinggi menara turbin yang 80 m. Ketiga, hubungan antara kecepatan angin yang diprediksi dan daya listrik yang dihasilkan tidak diuji dalam penelitian ini, padahal daya PLTB Sidrap tidak konstan akibat kecepatan angin yang berubah-ubah [4]. Jika data anemometer atau data

produksi PLTB tersedia, validasi terhadap data tersebut merupakan langkah lanjutan yang penting.

3.5 Keterbatasan

Penelitian ini memiliki beberapa keterbatasan:

1. Model hanya memanfaatkan variabel cuaca pada hari yang sama tanpa fitur historis (*lag*), sehingga pola waktu seperti musiman dan autokorelasi tidak dimanfaatkan.
2. Tidak dilakukan penyetelan hiperparameter maupun validasi silang berurutan waktu.
3. Kode cuaca WMO diperlakukan sebagai variabel numerik padahal bersifat kategorikal.
4. Data berasal dari satu titik lokasi dan berupa data grid, bukan pengukuran langsung.
5. Belum ada model pembanding sederhana (*baseline*) seperti model persisten atau regresi linear.
6. Hanya satu nilai *random seed* yang digunakan sehingga variasi hasil antarpercobaan belum diketahui.

4. Kesimpulan

Komparasi antara Random Forest dan XGBoost dijadikan fokus dalam penelitian ini untuk memprediksi kecepatan angin maksimum harian pada ketinggian 10 m di kawasan PLTB Sidrap, Sulawesi Selatan. Basis data yang dimanfaatkan mencakup 3.287 data harian Open-Meteo periode 2015-2023, sembilan variabel prediktor, serta dua skenario pembagian data berurutan waktu, yakni 70:30 dan 80:20. Berlandaskan hasil percobaan, simpulan yang diperoleh adalah sebagai berikut:

1. Kedua model mampu memprediksi kecepatan angin maksimum harian dengan akurasi moderat, dengan R^2 berkisar 0,5446-0,5968, MAE 2,2270-2,3155 km/jam, dan RMSE 2,8043-2,9454 km/jam. Galat rata-rata tersebut setara sekitar 14,6%-15,1% dari rata-rata kecepatan angin seluruh data (15,31 km/jam).
2. XGBoost memberikan kinerja lebih baik daripada Random Forest pada kedua skenario. Hasil terbaik diperoleh XGBoost dengan pembagian 80:20 (MAE 2,2270 km/jam, RMSE 2,8043 km/jam, R^2 0,5968), yang menurunkan MAE sekitar 2,0% dan RMSE sekitar 2,3% dibandingkan Random Forest pada skenario yang sama.
3. Kedua model menunjukkan kinerja lebih baik pada skenario 80:20 daripada 70:30. Namun, periode data uji kedua skenario berbeda dan selisih metriknya kecil, sehingga perbedaan tersebut tidak sepenuhnya dapat dikaitkan dengan ukuran data latih.
4. Kelembapan relatif merupakan variabel paling berpengaruh pada kedua model (kepentingan 0,2335 pada Random Forest dan 0,3355 pada XGBoost), diikuti suhu maksimum (0,2017 dan 0,1756). Tutupan awan memiliki kontribusi terkecil. Urutan ini konsisten dengan analisis korelasi yang menunjukkan kelembapan relatif sebagai variabel dengan hubungan linear terkuat terhadap target ($r = -0{,}4583$).
5. Selisih kinerja antarmodel relatif kecil dan percobaan memakai satu nilai *random seed*, sehingga keunggulan XGBoost lebih tepat dipandang sebagai indikasi daripada kesimpulan yang pasti. Selain itu, karena data berasal dari grid model cuaca pada ketinggian 10 m, hasil ini lebih cocok dijadikan *baseline* daripada sistem peramalan operasional bagi PLTB Sidrap.

Saran untuk penelitian selanjutnya, beberapa hal dapat dilakukan:

1. Menambahkan fitur historis (*lag*) dan fitur musiman agar pola waktu dapat dimanfaatkan model.
2. Melakukan penyetelan hiperparameter dan validasi silang yang memperhatikan urutan waktu.
3. Menambahkan model pembanding sederhana (misalnya model persisten atau regresi linear) serta model deret waktu seperti LSTM.
4. Memvalidasi model dengan data anemometer atau data produksi PLTB Sidrap, serta menggunakan kecepatan angin pada ketinggian poros turbin.
5. Mengulang percobaan dengan beberapa nilai *random seed* untuk mengetahui variasi hasil, serta memperlakukan kode cuaca sebagai variabel kategorikal.

REFERENSI

[1] N. A. Pambudi *et al.*, "Renewable Energy in Indonesia: Current Status, Potential, and Future Development," *Sustainability*, vol. 15, no. 3, p. 2342, 2023, doi: 10.3390/su15032342.

[2] K. E. RI, "Resmikan 'Kebun Angin' Raksasa Pertama di Indonesia, Presiden Jokowi: Seperti di Eropa, tapi di Sidrap," 2018.

[3] A. Zabihi, V. B. Manur, Y. Dintakurthy, K. R. K. V. Prasad, P. Rene, and V. B. M. Krishna, "Machine learning-based wind speed forecasting: a comparative study," *Sci. Rep.*, vol. 15, no. 1, p. 40866, 2025, doi: 10.1038/s41598-025-24640-1.

[4] M. K. Asy'ari, V. S. S. Sitanggang, and A. Musyafa', "Perancangan Sistem Prediksi Daya Listrik PLTB Sidrap Menggunakan Model Autoregressive," in *Prosiding Seminar Nasional Teknik Elektro, Sistem Informasi, dan Teknik Informatika (SNESTIK III)*, 2023, pp. 144–151. doi: 10.31284/p.snestik.2023.4048.

[5] F. W. Mugware, C. Sigauke, and T. Ravele, "Evaluating Wind Speed Forecasting Models: A Comparative Study of CNN, DAN2, Random Forest and XGBoost in Diverse South African Weather

Conditions," *Forecasting*, vol. 6, no. 3, pp. 672–699, 2024, doi: 10.3390/forecast6030035.

[6] H. Elmousalami, H. H. Elmesalami, M. Maxi, A. A. K. M. Farid, and N. Elshaboury, "A comprehensive evaluation of machine learning and deep learning algorithms for wind speed and power prediction," *Decis. Anal. J.*, vol. 13, p. 100527, 2024, doi: 10.1016/j.dajour.2024.100527.

[7] J. Sathyaraj and V. Sankardoss, "A novel analysis of random forest regression model for wind speed forecasting," *Cogent Eng.*, vol. 11, p. 2434617, 2024, doi: 10.1080/23311916.2024.2434617.

[8] I. Hussain, K. B. Ching, C. Uttraphan, K. G. Tay, I. Memon, and S. A. Memon, "Predicting Monthly Wind Speeds Using XGBoost: A Case Study for Renewable Energy Optimization," *Processes*, vol. 13, no. 6, p. 1763, 2025, doi: 10.3390/pr13061763.

[9] B. Kim and K. Ko, "Application of multi-source data for improvement of day-ahead wind power forecasting with machine learning models," *J. Mech. Sci. Technol.*, vol. 39, pp. 7921–7930, 2025, doi: 10.1007/s12206-025-1147-8.

[10] A. Zhu, Q. Zhao, T. Yang, L. Zhou, and B. Zeng, "Wind speed prediction and reconstruction based on improved grey wolf optimization algorithm and deep learning networks," *Comput. Electr. Eng.*, vol. 114, p. 109074, 2024, doi: 10.1016/j.compeleceng.2024.109074.

[11] D. Geng, Y. Zhang, Y. Zhang, X. Qu, and L. Li, "A hybrid model based on CapSA-VMD-ResNet-GRU-attention mechanism for ultra-short-term and short-term wind speed prediction," *Renew. Energy*, vol. 240, p. 122191, 2025, doi: 10.1016/j.renene.2024.122191.

[12] M. Du, Z. Zhang, and C. Ji, "Prediction for Coastal Wind Speed Based on Improved Variational Mode Decomposition and Recurrent Neural Network," *Energies*, vol. 18, no. 3, p. 542, 2025, doi: 10.3390/en18030542.

[13] S. Chatterjee, P. W. Khan, and Y.-C. Byun, "Recent advances and applications of machine learning in the variable renewable energy sector," *Energy Reports*, vol. 12, pp. 5044–5065, 2024, doi: 10.1016/j.egyr.2024.09.073.

[14] B. O. Abisoye, Y. Sun, and W. Zenghui, "A survey of artificial intelligence methods for renewable energy forecasting: Methodologies and insights," *Renew. Energy Focus*, vol. 48, p. 100529, 2024, doi: 10.1016/j.ref.2023.100529.

[15] F. Houndekindo and T. B. M. J. Ouarda, "Prediction of hourly wind speed time series at unsampled locations using machine learning," *Energy*, vol. 299, p. 131518, 2024, doi: 10.1016/j.energy.2024.131518.

[16] S. Guan, Y. Wang, L. Liu, J. Gao, Z. Xu, and S. Kan, "Ultra-short-term wind power prediction method based on FTI-VACA-XGB model," *Expert Syst. Appl.*, vol. 235, p. 121185, 2024, doi: 10.1016/j.eswa.2023.121185.

[17] S. M. Malakouti, "Estimating the output power and wind speed with ML methods: A case study in Texas," *Case Stud. Chem. Environ. Eng.*, vol. 7, p. 100324, 2023, doi: 10.1016/j.cscee.2023.100324.

[18] Tirto.id, "PLTB Sidrap yang Pertama di Indonesia Diresmikan Jokowi Hari Ini," 2018.

[19] P. Zippenfenig, "Open-Meteo.com Weather API," 2023, *Zenodo*. doi: 10.5281/zenodo.7970649.

[20] P. Potisomporn, T. A. A. Adcock, and C. R. Vogel, "Evaluating ERA5 reanalysis predictions of low wind speed events around the UK," *Energy Reports*, vol. 10, pp. 4781–4790, 2023, doi: 10.1016/j.egyr.2023.11.035.

[21] M. Alkhalidi, A. Al-Dabbous, and S. Al-Dabbous, "Evaluating the Accuracy of the ERA5 Model in Predicting Wind Speeds Across Coastal and Offshore Regions," *J. Mar. Sci. Eng.*, vol. 13, no. 1, p. 149, 2025, doi: 10.3390/jmse13010149.

[22] S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science," *Patterns*, vol. 4, no. 9, p. 100804, 2023, doi: 10.1016/j.patter.2023.100804.

[23] J. Wang, Y. Liu, S. Shu, and X. He, "A coupling deterministic and probabilistic wind energy prediction based on information leakage prevention and distinctive deep learning network," *Eng. Appl. Artif. Intell.*, vol. 152, p. 110862, 2025, doi: 10.1016/j.engappai.2025.110862.